

Отчёт: Анализ пользовательских предпочтений (NMF)

- 1. Исходные данные
 - Таблица ratings (превью)
 - Таблица movies (превью)
- 2. Основные метрики данных
- 3. Результаты матричного разложения (NMF)
- 4. Топ самых оцениваемых жанров
- 5. Интерпретация латентных факторов через жанры
- 6. Выводы

1. Исходные данные

Таблица ratings (превью)

```
if (exists("ratings")) {
  ratings %>% select(userId, movieId, rating) %>% head() %>% knitr::kable()
} else {
  cat("Таблица ratings не найдена\n")
}
```

userId	movieId	rating
1	1	4
1	1	3
1	1	6
1	1	47
1	1	50
1	1	70

Таблица movies (превью)

```
if (exists("movies")) {
  movies %>% select(movieId, title, genres) %>% head() %>% knitr::kable()
} else {
  cat("Таблица movies не найдена\n")
}
```

movieId	title	genres
1	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
2	Jumanji (1995)	Adventure Children Fantasy
3	Grumpier Old Men (1995)	Comedy Romance
4	Waiting to Exhale (1995)	Comedy Drama Romance
5	Father of the Bride Part II (1995)	Comedy
6	Heat (1995)	Action Crime Thriller

2. Основные метрики данных

```
library(ggplot2)
```

```
# Числовые метрики
```

```
if (exists("ratings")) {
```

```
  cat("• Средняя оценка:", round(mean(ratings$rating), 3), "\n")
```

```
  cat("• Медиана:", median(ratings$rating), "\n")
```

```
  cat("• Стандартное отклонение:", round(sd(ratings$rating), 3), "\n")
```

```
  cat("• Мин/Макс:", min(ratings$rating), "/", max(ratings$rating), "\n")
```

```
  cat("• Всего оценок:", nrow(ratings), "\n")
```

```
  cat("• Уникальных пользователей:", length(unique(ratings$userId)), "\n")
```

```
  cat("• Уникальных фильмов:", length(unique(ratings$movieId)), "\n\n")
```

```
}
```

```
# Гистограмма распределения
```

```
ggplot(ratings, aes(x = rating)) +
```

```
  geom_histogram(binwidth = 0.5, color = "#FFE4E1", fill = "#8B0000", alpha = 0.9) +
```

```
  scale_fill_gradient(low = "#CD5C5C", high = "#8B0000")
```

```
+
```

```
  labs(title = "Распределение пользовательских оценок",
```

```
        x = "Оценка", y = "Количество") +
```

```
  theme_minimal() +
```

```
  theme(legend.position = "none")
```

```
} else {
```

```
  cat("Данные для анализа не загружены\n")
```

```
}
```

```
## • Средняя оценка: 3.502
```

```
## • Медиана: 3.5
```

```
## • Стандартное отклонение: 1.043
```


```
## • Мин/Макс: 0.5 / 5
```

```
## • Всего оценок: 100836
```

```
## • Уникальных пользователей: 610
```

```
## • Уникальных фильмов: 9724
```

Распределение пользовательских оценок



3. Результаты матричного разложения (NMF)

```

if (exists("W") && exists("H")) {
  cat("Матрица W (пользователи × латентные факторы):\n")
  cat("  Размерность:", paste(dim(W), collapse = " × "), "\n")
  cat("  Диапазон весов: [", round(min(W), 4), "; ", round(max(W), 4), "]\n\n", sep="")
}

cat("Матрица H (латентные факторы × фильмы):\n")
}

cat("  Размерность:", paste(dim(H), collapse = " × "), "\n")
cat("  Диапазон нагрузок: [", round(min(H), 4), "; ", round(max(H), 4), "]\n", sep="")
} else {
  cat("⚠ Матрицы W и H не найдены. Выполните код NMF перед компиляцией отчёта.\n")
}

```

```

## Матрица W (пользователи × латентные факторы):
##   Размерность: 221 × 3
##   Диапазон весов: [0; 0.2754]
##
## Матрица H (латентные факторы × фильмы):
##   Размерность: 3 × 222
##   Диапазон нагрузок: [0; 44.2102]

```

4. Топ самых оцениваемых жанров


```

if (exists("ratings") && exists("movies")) {
  # Подсчёт количества оценок по жанрам
  genre_counts <- ratings %>%
    left_join(movies %>% select(movieid, genres), by = "movieid") %>%
    filter(!is.na(genres)) %>%
    separate_rows(genres, sep = "\\|") %>%
    count(genres, sort = TRUE) %>%
    head(10) %>%
    rename(Genre = genres, Count = n)
}

# Визуализация
ggplot(genre_counts, aes(x = reorder(Genre, Count), y = Count)) +
  geom_bar(stat = "identity", fill = "#CD5C5C", alpha = 0.8) +
  coord_flip() +
  labs(
    title = "Топ-10 самых оцениваемых жанров",
    x = "Жанр",
    y = "Количество оценок"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(color = "#8B0000", face = "bold"),
    plot.subtitle = element_text(color = "#A52A2A")
  )
} else {
  cat("Необходимые данные не загружены\n")
}

```

Топ-10 самых оцениваемых жанров




5. Интерпретация латентных факторов через жанры

```

if (exists("H") && exists("movies")) {
  # 1. Создаём таблицу: фильмы x их нагрузка на факторы
  H_df <- as.data.frame(t(H)) %>%
    mutate(MovieID = as.numeric(colnames(H)))
  # 2. Присоединяем жанры
  H_genres <- H_df %>%
    left_join(movies %>% select(movieid, genres), by = c("MovieID" = "movieid")) %>%
    filter(!is.na(genres)) %>%
    separate_rows(genres, sep = "\\|")
  # 3. Считаем среднюю нагрузку каждого жанра на каждый фактор
  factor_genre_load <- H_genres %>%
    pivot_longer(cols = -c(MovieID, genres), names_to = "Factor", values_to = "Load") %>%
    group_by(genres, Factor) %>%
    summarise(mean_load = mean(Load, na.rm = TRUE), .groups = "drop") %>%
    filter(!is.na(genres), mean_load > 0)
  # 4. Визуализация: тепловая карта "Фактор x Жанр"
  ggplot(factor_genre_load, aes(x = Factor, y = reorder(genres, mean_load), fill = mean_load)) +
    geom_tile() +
    scale_fill_gradient(low = "#FFF0F0", high = "#8B0000", name = "Нагрузка")
  +
  labs(
    title = "Интерпретация латентных факторов через жанры",
    x = "Латентный фактор",
    y = "Жанр"
  ) +
  theme_minimal() +
  theme(
    plot.title = element_text(color = "#8B0000", face = "bold"),
    plot.subtitle = element_text(color = "#A52A2A"),
    axis.text.y = element_text(size = 8)
  )
} else {
  cat("⚠ Матрица H или таблица movies не найдены\n")
}

```

Интерпретация латентных факторов через жанры



6. Выводы

- 1. **Данные:** Датасет содержит 100836 оценок от 610 пользователей для 9724 фильмов.
- 2. **NMF:** Метод успешно снизил размерность данных, выделив латентные факторы предпочтений. Матрицы W и H позволяют интерпретировать скрытые паттерны через жанровую принадлежность фильмов.
- 3. **Автоматизация:** Данный отчёт сгенерирован автоматически через RMarkdown. Все графики, таблицы и метрики обновляются при повторном запуске, что обеспечивает воспроизводимость исследования.